

Макет программного средства геолокация по фото для задач OSINT

Подготовил: НДП

Руководитель: ЖАГ

Цель и задачи

2/14

Цель: создание макета программного средства определения геолокации по изображению с помощью глубокого обучения

Задачи:

1. Обзор существующих методов и средств определения геолокации по изображению с использованием методов глубокого обучения
2. Поиск источников данных и исследование возможностей их использования для формирования обучающей выборки
3. Формирование набора обучающих данных
4. Обучение модели на сформированном наборе данных
5. Выбор метрик качества и оценка качества обученной модели по выбранным метрикам
6. Создание макета и экспериментальное исследование его возможностей и ограничений для практического использования

Оперативно-розыскная
деятельность

Определение местоположения
точки съёмки фото и видео при
проведении оперативно-
розыскных мероприятий

Скомпрометированные
камеры

Определение географических
координат сетевых камер
видеонаблюдения, захваченных
злоумышленниками

Отслеживание
передвижений

Мониторинг перемещения
техники и личного состава по
фотоматериалам из открытых
источников

Обзор существующих методов и средств определения геолокации по изображению с использованием методов глубокого обучения

4/14

Средство	Метод	Средство	Метод	Метод	Пояснение
IM2GPS	Поиск	GeoCLIP	Выравнивание	Поиск	Кодирует фото в вектор-дескриптор, ищет ближайший в базе референсных снимков с известными координатами. Координаты найденного снимка - ответ
NetVLAD	Поиск	AnyLoc	Поиск	Классификация	Делит карту на ячейки (классы), модель предсказывает в какую ячейку попадает фото. Точность ограничена размером ячейки
PlaNet	Классификация	GeoVista	Рассуждение	Регрессия	Напрямую предсказывает числа широты и долготы по фотографии
Deep IM2GPS	Поиск	SegVLAD	Поиск	Рассуждение	Языковая модель (VLM) смотрит на фото, анализирует визуальные подсказки и называет координаты текстом
CPlaNet	Классификация	LocDiff	Регрессия	Гибридный	Комбинирует несколько подходов
VIGOR	Регрессия	Kopernik	Гибридный	Выравнивание	Совмещает уличный снимок с картой или спутниковым изображением, определяя координаты через пространственное сопоставление
MvMF	Гибридный	GeoAgent	Рассуждение		
CosPlace	Поиск	GAEA	Рассуждение		

PlaNet не имеет открытого исходного кода

Поиск источников для обучающей выборки и исследование возможности их использования для формирования набора обучающих данных

5/14

№	Объем выборки (тыс)	Название источника
1	6 472	Im2GPS
2	250	Pittsburgh 250k
3	11	Revisited Oxford/Paris
4	126 000	PlaNet
5	5 000	Google Landmarks Dataset
6	3	Im2GPS3k
7	4	YFCC4k
8	35	CVUSA
9	92,5	CVACT
10	2,5	University-1652

11	1 600	Mapillary
12	1 000	MediaEval
13	100	Kaggle
14	30	Pitts30K
15	689	Baidu Mall
16	5	InsideOut
17	76	Tokyo 24/7
18	40 900	SFXL
19	22	VPair
20	2,5	AmsterTime
21	10	GeoSeek-CoT

Поиск источников данных и формирование набора данных


6/14



Данные полученные с помощью selenium




Очистка данных полученных с помощью Google API



Пустые изображения
полученные с помощью
Google API

Тип запроса	Количество	Пояснение
Metadata (/metadata)	7 520	По одному на каждую из 7 520 точек сетки
Image download	16 139	3 ракурса × 5 380 найденных панорам
Итого	23 659	Почти ровно у дневного лимита (24 000)
Метрика		Значение
Всего запросов		23 659
Общее время		48 821 с
Средняя скорость		≈ 0,48 запроса/сек (≈ 1 745 запросов/час)
Среднее время на точку сетки		≈ 6,5 с (с учётом сетевых задержек)
Скачано изображений в час		≈ 1 190 кадров/час


Статистика запросов к API



Всего	5004 локаций / 14 969 изображений
Обучающая выборка	3964 локаций / 11853 изображений
Валидационная выборка	523 локаций / 1569 изображений
Тестовая выборка	517 локаций / 1547 изображений

Обучение моделей

9/14



Коперник

GeoCLIP

GeoAgent

Коперник — регрессия ResNet-50, предсказывает GPS напрямую

GeoCLIP — семантическое выравнивание изображения с координатами

GeoAgent — языковая модель Qwen2.5-VL с LoRA

Таблица значений обучения моделей

	Районов	Точек съёмки	Фотографий
Train	80	3 964	11 853
Val	10	523	1 569
Test	10	517	1 547
Итого	100	5 004	14 969



Подход	Как получаем координаты	Модели
Регрессия	Напрямую предсказываем (lat, lon)	GAEA, Kopernik, TransGeo
Классификация	Выбираем S2-ячейку → центр ячейки	Deep IM2GPS, CPlaNNet
Поиск по базе	Дескриптор → ближайший train-снимок	NetVLAD, AnyLoc
Выравнивание	Эмбеддинг → ближайшая GPS в совместном пространстве	GeoCLIP, VIGOR, GeoVista
Генерация текста	LLM пишет координаты в JSON	GeoAgent

Модель	Обучено эпох	Лучшая эпоха	Время обучения
GeoAgent (Qwen 2.5-VL + LoRA)	40	39	—
GAEA (CLIP ViT-L/14)	55	41	~2ч 36мин
GeoCLIP	26	19	~1ч 34мин
Kopernik (baseline)	19	13	~28 мин
LocDiff	25	10	~2ч
CPlaNNet	28	19	~42 мин
Deep IM2GPS	34	26	~25 мин
TransGeo	20	12	~35 мин
MvMF	12	1	~4 мин
AnyLoc (zero-shot)	—	—	~5 мин
NetVLAD	19	9	~1ч 12мин
ConceptAwareGeo	17	8	~1ч 31мин
GeoVista	14	6	~40 мин
VIGOR	13	5	~40 мин
SegVLAD	23	13	~1ч 36мин

Выбор метрик качества и оценка качества обученных моделей по выбранным метрикам

Метод	Средняя ошибка (Mean), м
GeoAgent	2 854
GeoCLIP	3 100
Kopernik (Baseline)	3 545
LocDiff	3 546
CPlaNet	3 972
Deep IM2GPS	4 005
GAEA	4 345
MvMF	4 829
CosPlace	4 912
NetVLAD	5 025
AnyLoc	5 264
GeoVista	5 286
VIGOR	5 330
SegVLAD	5 989

Интерфейс программного средства



Технические ограничения макета программного средства

13/14

#	Ограничение	Значение
1	Максимальный размер загружаемого файла	20 МБ
2	Поддерживаемые форматы	JPEG, PNG, WebP, BMP
3	Время инференса	25–45 с / запрос
4	Одновременных запросов	1
5	Минимальный GPU (VRAM)	8 ГБ (рекомендуется 12+)
6	Минимальный CPU RAM	16 ГБ
7	Область применения	Только визуально узнаваемые места
8	Язык интерфейса модели	Английский (промпт/CoT)
9	ОС для запуска	Windows / Linux
10	Загрузка модели при старте	25–30 с
11	Пакетная обработка	Не поддерживается

1. Проведён обзор **16** существующих методов геолокализации по изображению в рамках 5 методов (поиск, классификация, регрессия, выравнивание, рассуждение). Установлено, что подходы на основе VLM показывают наилучший потенциал для городской среды.
2. Сформирован датасет Moscow ТТК-10k: 5 004 уникальных локации, 14 969 изображений Google Street View. Разбивка на выборки выполнена методом K-Means (k=100) по координатам — 80% train / 10% val / 10% test — что исключает географическую утечку данных.
3. Обучено и протестировано 14 архитектур на собранном датасете. Метрика оценки — Raw Per-Image Mean Haversine Distance. Результаты варьируются от 2 854 м (GeoAgent) до 5 989 м (SegVLAD).
4. Лучший результат достигнут моделью GeoAgent (Qwen2.5-VL-7B + LoRA rank-64): средняя ошибка — 2 854 м, медианная — 2 106 м, Recall@1km — 24.1%, Recall@3km — 61.2%. Дообучение улучшило результат в 6.3 раза относительно zero-shot baseline (17 844 м).
5. Разработан веб-макет на Flask для применения в задачах OSINT: пользователь загружает фотографию, система возвращает предсказанные координаты и отображает точку на карте.